




DYNAMIC NEURAL NETWORKS



PRESENTACIÓN




27/10/2025

EL PROBLEMA CON LAS REDES TRADICIONALES


SIS421

PROBLEMA PRINCIPAL: "TALLA ÚNICA PARA TODOS" (ONE-SIZE-FITS-ALL)



EJEMPLO DEL MUNDO REAL

- Imagina un aeropuerto donde todos pasan por el mismo control
- Pasajeros sin equipaje esperan igual que quien trae 5 maletas
- ¡Desperdicio de tiempo para viajeros ligeros!




EN REDES NEURONALES

- Todas las imágenes pasan por TODAS las capas
- Una imagen simple de un cielo azul → 100 capas
- Una imagen compleja de una escena urbana → 100 capas
- ¿Por qué procesar lo simple como si fuera complejo?


CONSECUENCIAS

- Alto consumo energético
- Mayor latencia
- Costos computacionales innecesarios



INTRODUCCIÓN A DNN

"NO TODAS LAS ENTRADAS SON IGUALES, ¿POR QUÉ DEBERÍAN SER PROCESADAS IGUAL?"



¿QUÉ SON LAS REDES NEURONALES DINÁMICAS?


Redes que pueden adaptar su arquitectura o parámetros basándose en cada entrada específica.

DIFERENCIAS FUNDAMENTALES:

Aspecto	Redes Estáticas	Redes Dinámicas
Arquitectura	Fija	Adaptativa
Cómputo	Igual para todo	Variable según entrada
Eficiencia	Baja	Alta
Latencia	Constante (alta)	Variable (menor promedio)


INSTANCE-WISE (POR MUESTRA)

- Adapta para cada imagen/texto individual
- Ejemplo: Una foto clara → usa 2 capas, foto borrosa → usa 10 capas
- Más común y lo que implementaremos




SPATIAL-WISE (ESPACIAL)

- Adapta según ubicación en la imagen
- Ejemplo: Fondo → procesamiento ligero, objeto principal → procesamiento profundo
- Útil en detección de objetos




TEMPORAL-WISE (TEMPORAL)


- Adapta a lo largo del tiempo en videos
- Ejemplo: Frames similares → reutilizar cálculos anteriores
- Útil en reconocimiento de acciones



TRES TIPOS PRINCIPALES DE REDES DINÁMICAS

TAXONOMÍA DE DNN





EARLY EXITING: SALIR CUANDO ESTÉS SEGURO


Si la red está muy segura de su predicción en una capa temprana, ¿por qué continuar procesando?

PUNTOS CLAVE:

- Múltiples "exit points" o salidas intermedias
- Cada exit tiene su propio clasificador
- Decisión basada en confianza de la predicción

SIS421

EARLY EXITING EL CONCEPTO



MIDIENDO LA CONFIANZA - ENTROPIA

¿CÓMO SABER SI LA RED ESTÁ SEGURA?

USAMOS ENTROPIA (H) DE SHANNON:

$$H' = - \sum_{i=1}^S p_i \log_2 p_i$$

ALTA CONFIANZA
(ENTROPIA BAJA)

Predicción: [0.95, 0.01, 0.01, 0.01, 0.01, 0.01, ...]

└─ Avión

Entropía $\approx 0.2 \rightarrow$ "¡Estoy 95% seguro que es un avión!"

DECISIÓN: SALIR TEMPRANO


BAJA CONFIANZA
(ENTROPIA ALTA)

Predicción: [0.3, 0.25, 0.2, 0.15, 0.05, 0.05, ...]

Entropía $\approx 1.5 \rightarrow$ "No estoy seguro... ¿perro? ¿gato?"

DECISIÓN: CONTINUAR PROCESANDO

ENTROPY < 0.5 $\rightarrow$ SALIDA TEMPRANA



ENTRENAMIENTO VS INFERENCIA

DOS FASES DISTINTAS

- Se usan *TODAS* las capas *SIEMPRE*
- Cada exit point tiene su clasificador
- Pérdida combinada de todos los exits
- Objetivo: Entrenar todos los clasificadores para que sean buenos
- No hay dinamismo aquí

FASE 1: ENTRENAMIENTO


- Aquí es donde ocurre la *MAGIA*
- Para cada nueva imagen:
- Procesa Bloque 1 → evalúa confianza
- Si confianza baja → Procesa Bloque 2 → evalúa
- Si confianza baja → Procesa Bloque 3
- Dinamismo completo

FASE 2: INFERENCIA (PREDICCIÓN)

ANALOGÍA

ENTRENAMIENTO = ESTUDIAR TODO EL MATERIAL DEL CURSO

INFERENCIA = EN EL EXAMEN, RESPONDER SEGÚN DIFICULTAD DE CADA PREGUNTA



VENTAJAS DE LAS DNN

¿POR QUÉ USAR REDES DINÁMICAS?

1. Eficiencia Computacional

- Ahorro típico: 30-70% de FLOPs
- Muestras simples (mayoría) → procesamiento rápido
- Recursos reservados para casos complejos

2. Menor Latencia

- Tiempo promedio de inferencia reducido
- Speedups de 2x-6x reportados en literatura
- Crítico para aplicaciones real-time

3. Ahorro Energético


- Menos computación = menos energía
- Ideal para dispositivos móviles
- Importante para Green AI y sostenibilidad

4. Mejor Experiencia de Usuario

- Respuestas más rápidas
- Mayor throughput en servidores
- Posibilidad de correr modelos más grandes

5. Adaptabilidad

- Se ajusta automáticamente a complejidad de entrada
- No necesita ajuste manual por tipo de dato



CASOS DE USO

¿CUÁNDO USAR REDES DINÁMICAS?



IDEAL PARA:

Datasets con Variabilidad Alta

- Mezcla de imágenes simples y complejas

Aplicaciones con Restricciones de Latencia

- Apps móviles
- Sistemas embedded
- Real-time video processing

Batch Processing Heterogéneo

- Cuando las muestras tienen diferentes dificultades
- Cloud services con cargas variables

Edge Computing

- Recursos limitados
- Batería limitada
- Necesidad de eficiencia

NO IDEAL PARA:

Datasets Uniformes


- Todas las muestras tienen complejidad similar
- Ejemplo: MNIST (muy simple)

Aplicaciones Críticas donde Accuracy es Prioritario

- Diagnóstico médico
- Control de calidad industrial
- Donde no se puede tolerar pérdida de precisión

Sistemas con Requisitos Determinísticos Estrictos

- Latencia debe ser constante y predecible
- Sistemas real-time hard



APLICACIONES EN EL MUNDO REAL

¿DÓNDE SE USA ESTO?

L	L	L	L	L
1. VISIÓN POR COMPUTADORA <i>Clasificación de Imágenes</i> • Apps de fotos, organización de galerías • Imágenes simples procesadas 3x más rápido <i>Detección de Objetos</i> • Cámaras de seguridad, vehículos autónomos, retail • Fondos simples ahorran 50-70% de cómputo <i>Reconocimiento Facial</i> • Desbloqueo de smartphones, control de acceso • Fotos claras salen temprano, ahorra batería	2. PROCESAMIENTO DE LENGUAJE NATURAL <i>Modelos de Lenguaje (BERT, GPT)</i> • Búsqueda, chatbots, autocompletado • Reducción de latencia <i>Traducción Automática</i> • Google Translate, subtítulos automáticos • Frases simples traducidas más rápido <i>Análisis de Sentimientos</i> • Monitoreo de redes sociales, reseñas de productos • Procesamiento real-time de millones de textos <i>Clasificación de Texto</i> • Filtrado de spam, organización de emails • Reducción en costos de servidor	3. PROCESAMIENTO DE VIDEO <i>Reconocimiento de Acciones</i> • Vigilancia, análisis deportivo, detección de caídas • Menos cómputo explotando frames similares <i>Análisis de Video en Tiempo Real</i> • Streaming, moderación de contenido • Procesar solo frames con cambios significativos	4. DISPOSITIVOS MÓVILES Y EDGE <i>Smartphones</i> • Asistentes de voz, cámara inteligente • Menos consumo de batería <i>IoT y Sensores</i> • Smart home, wearables, sensores industriales • Funcionar en dispositivos con recursos limitados <i>Edge Computing</i> • Cámaras de seguridad, drones, robótica • Decisiones locales rápidas, cloud solo para casos complejos	5. CLOUD Y DATACENTER <i>Servicios Web</i> • APIs de ML, plataformas de AI • Mayor throughput, menor costo operativo <i>Batch Processing</i> • Análisis de grandes datasets • Procesar cargas heterogéneas eficientemente <i>Microservicios de AI</i> • Recomendaciones, búsqueda, ranking • Escalar mejor con menos servidores

SIS421

GRACIAS

